Implementasi OpenClaw sebagai Asisten Otomasi Tugas Administratif Berbasis *Agentic AI*: Studi Implementatif dengan Uji Fungsional dan UAT

Abstrak

Penelitian ini menyajikan evaluasi implementatif OpenClaw sebagai asisten otomasi tugas administratif pada lingkungan kerja skala kecil. Karena belum tersedia dataset historis besar, evaluasi dilakukan melalui kombinasi *black-box testing* dan *User Acceptance Test* (UAT) dalam kerangka *pilot terbatas*. Uji fungsional mencakup 20 skenario (TC-01 s.d. TC-20) lintas manajemen berkas, eksekusi perintah, pengambilan informasi web, orkestrasi multi-langkah, dan integrasi dokumen. Hasil menunjukkan *strict pass rate* 95% (19/20), dengan satu kegagalan awal pada TC-14 akibat *timeout* layanan eksternal. Setelah satu kali *retry* terkontrol, keberhasilan operasional menjadi 100% (20/20), dengan *timeout rate* awal 5% dan 0% pada status akhir. UAT melibatkan 10 responden (8 item Likert 1–5). Berdasarkan agregasi per-responden, rerata keseluruhan 4,15 (SD 0,26; min 3,75; maks 4,63; median 4,13; IQR 4,00–4,38), yang berada pada kategori setuju. Temuan menunjukkan OpenClaw layak sebagai **pilot terbatas** untuk tugas administratif terstruktur, dengan prasyarat penguatan ketahanan *timeout*, observabilitas log, dan disiplin SOP operasional.

Kata kunci: OpenClaw, *agentic AI*, otomasi administrasi, *black-box testing*, UAT, evaluasi implementasi

---

1. Pendahuluan

1.1 Latar Belakang

Digitalisasi proses kerja mendorong organisasi mengurangi beban aktivitas administratif repetitif seperti pengelolaan berkas, peringkasan informasi, dan penyusunan dokumen rutin. Perkembangan mutakhir menunjukkan sistem AI tidak lagi hanya bertindak sebagai antarmuka tanya-jawab, tetapi sebagai agen yang dapat mengeksekusi alur kerja multi-langkah melalui integrasi berbagai *tools* [2]–[5].

OpenClaw memfasilitasi pola tersebut dengan menghubungkan model bahasa ke kemampuan tindakan terkontrol pada lingkungan kerja. Pada konteks organisasi kecil, karakteristik ini berpotensi meningkatkan efisiensi tugas administratif ketika SOP otomasi internal belum mapan.

1.2 Kesenjangan Penelitian (*Research Gap*)

Terdapat tiga kesenjangan utama. Pertama, studi terapan pada konteks administratif harian organisasi kecil masih terbatas dibanding studi *benchmark* umum [3], [8], [9]. Kedua, publikasi yang menggabungkan metrik teknis eksekusi dan penerimaan pengguna awal dalam protokol ringkas-replikatif masih relatif sedikit. Ketiga, pelaporan fase adopsi awal sering tidak menyertakan jejak audit insiden dan ketertelusuran kebutuhan ke bukti eksekusi.

1.3 Rumusan Masalah

1. Bagaimana implementasi OpenClaw mendukung otomasi tugas administratif terstruktur pada lingkungan operasional terbatas?

2. Sejauh mana fungsi inti OpenClaw berjalan sesuai harapan berdasarkan uji *black-box*?
3. Bagaimana tingkat penerimaan pengguna awal terhadap OpenClaw berdasarkan UAT?

1.4 Tujuan Penelitian

1. Mengimplementasikan OpenClaw pada skenario tugas administratif yang didefinisikan operasional.
2. Mengukur keberhasilan fungsi inti melalui 20 skenario *black-box*.
3. Mengukur penerimaan pengguna awal melalui UAT skala Likert pada 10 responden.
4. Menyajikan pelaporan defensif berbasis *single source of truth* data, termasuk analisis insiden.

1.5 Kontribusi Penelitian

1. Menyediakan desain evaluasi implementatif yang menggabungkan metrik teknis dan metrik pengguna pada fase adopsi awal.
2. Menyajikan instrumen replikatif (TC-01..TC-20 + UAT 8 item) yang konsisten antara naskah dan lampiran.
3. Menawarkan format pelaporan defensif: *strict pass rate*, *success-after-retry*, dan log audit insiden.

1.6 Batasan Penelitian

- Studi implementatif pada satu lingkungan operasional terbatas.
- Tidak menggunakan eksperimen komparatif antarmodel.
- UAT hanya 10 responden (tidak untuk generalisasi populasi luas).
- Horizon observasi jangka pendek.

1.7 Pernyataan Kebaruan (***Novelty Statement***)

Kebaruan penelitian ini terletak pada integrasi metrik teknis ketat (*pass/fail*, *timeout rate*, *success-after-retry*) dengan metrik penerimaan pengguna awal, disertai jejak audit operasional dan matriks ketertelusuran kebutuhan→TC→metrik→bukti pada konteks organisasi kecil.

---

2. Metode

2.1 Desain Penelitian

Penelitian menggunakan desain rekayasa implementatif dengan pendekatan deskriptif kuantitatif. Fokusnya adalah kelayakan awal operasional, bukan pengujian kausalitas atau superioritas model.

Tahap penelitian:

1. Identifikasi kebutuhan administratif.
2. Konfigurasi lingkungan OpenClaw.
3. Uji fungsional *black-box* (20 TC).
4. UAT (10 responden, 8 item).
5. Analisis deskriptif + forensik insiden.

2.2 Lingkungan Implementasi

Implementasi dijalankan pada server Linux dengan runtime Node.js, integrasi *tools* OpenClaw, dan konektivitas internet untuk layanan model/eksternal.

Komponen	Spesifikasi umum	Catatan
Sistem operasi	Linux server	Eksekusi otomasi stabil

Runtime	Node.js + integrasi *tools*	Mendukung orkestrasi multi-langkah
Jaringan	Internet aktif	Dibutuhkan untuk model/layanan eksternal
Penyimpanan	>10 GB	Log, artefak, dokumen hasil

2.3 Objek dan Unit Analisis

Objek penelitian adalah implementasi fungsi OpenClaw untuk tugas administratif terstruktur.

Unit analisis:

1. **Teknis:** hasil eksekusi tiap skenario (pass/fail, durasi, insiden).
2. **Pengguna:** persepsi responden melalui skor Likert.

2.4 Instrumen Penelitian

2.4.1 Instrumen *Black-Box* (TC-01..TC-20)

Tabel berikut adalah **definisi kanonik** TC-01..TC-20 yang juga digunakan identik pada lampiran.

ID	Deskripsi skenario	*Expected output*	*Pass criteria*
TC-01	Membuat file teks baru pada direktori target	File baru terbentuk dengan nama dan isi awal sesuai perintah	Lokasi benar, nama benar, isi awal sesuai instruksi
TC-02	Membaca file teks valid	Isi file tampil utuh	Konten terbaca lengkap tanpa korupsi karakter
TC-03	Mengedit file dengan *exact replace* pada segmen tertentu	Segmen target berubah, bagian lain tetap	Perubahan tepat pada target dan tidak merusak bagian non-target
TC-04	Meringkas dokumen lokal lalu menyimpan hasil	Ringkasan tersimpan dalam file baru	Ringkasan relevan, panjang sesuai batas instruksi
TC-05	Menjalankan perintah shell daftar direktori	Daftar file/folder tampil	Output shell valid dan sesuai direktori kerja
TC-06	Menjalankan perintah shell statistik berkas	Statistik jumlah/ukuran berkas diperoleh	Nilai statistik konsisten dengan kondisi aktual
TC-07	Melakukan *web search* kueri administratif	Tautan hasil pencarian relevan	Minimal satu sumber relevan sesuai kueri
TC-08	Mengambil konten dari URL valid (*web fetch*)	Konten utama halaman terekstrak	Informasi inti dapat dibaca dan ditelusuri sumbernya
TC-09	Mengambil konten dari URL tidak valid	Sistem memberi respons kegagalan terkontrol	Pesan error jelas, tidak menimbulkan keluaran menyesatkan
TC-10	Menyusun memo otomatis dalam markdown	Draf memo lengkap (judul–isi–penutup)	Struktur memo lengkap dan dapat dipakai setelah revisi minor

TC-11	Membuat keluaran tabel markdown	Tabel markdown valid	Sintaks tabel valid dan terbaca benar
TC-12	Orkestrasi 2 langkah (*search* lalu *summarize*)	Kedua langkah selesai berurutan	Hasil ringkas konsisten dengan sumber yang dicari
TC-13	Orkestrasi 3 langkah (buat–isi–simpan dokumen)	Artefak dokumen akhir terbentuk	Semua langkah selesai dan file akhir tersimpan
TC-14	Akses layanan eksternal dengan batas waktu 120 detik	Respons selesai dalam SLA atau tercatat timeout + retry	Pass awal jika selesai <120 detik; bila timeout, wajib ada log retry terkontrol
TC-15	Menangani perintah invalid pada eksekusi	Sistem mengembalikan error informatif	Pesan error menyebut penyebab dan langkah lanjut
TC-16	Memvalidasi input tidak valid/tidak aman	Input ditolak aman	Sistem tidak mengeksekusi input tidak valid
TC-17	Mengulang tugas serupa untuk cek konsistensi	Hasil ulang memiliki substansi setara	Variasi format minor diperbolehkan, substansi inti konsisten
TC-18	Mematuhi batas ruang lingkup tugas	Sistem tidak keluar konteks/perizinan	Aksi berisiko tidak dijalankan tanpa persetujuan eksplisit
TC-19	Uji reproduksibilitas SOP	Eksekusi ulang mengikuti prosedur yang sama	Hasil tetap konsisten lintas pengulangan SOP
TC-20	Integrasi akhir (kompilasi ringkasan + artefak)	Laporan akhir sinkron dengan sumber	Ringkasan, data sumber, dan file output saling konsisten

2.4.2 Instrumen UAT

UAT menggunakan 8 item Likert 1–5:

1. kemudahan penggunaan, 2) kejelasan instruksi, 3) relevansi hasil, 4) kecepatan membantu tugas, 5) pengurangan kerja manual, 6) kenyamanan penggunaan ulang, 7) kejelasan penanganan error, 8) manfaat terhadap produktivitas.

2.5 Sampel

Sampel UAT berjumlah 10 responden (purposif): 6 staf administrasi, 2 koordinator operasional, 2 asisten manajer.

2.6 Prosedur Pengumpulan Data

1. Eksekusi 20 TC dan pencatatan *pass/fail* + durasi.
2. Pencatatan insiden (timestamp, durasi, retry, outcome).
3. Pengisian UAT setelah sesi uji tugas.
4. Verifikasi silang angka naskah terhadap lampiran (satu sumber data final).

2.7 Definisi Outcome

Definisi outcome mengikuti prinsip evaluasi kualitas perangkat lunak yang operasional dan terukur [1].

1. **Pass awal (strict):** output memenuhi *expected output* dan *pass criteria* pada eksekusi awal.
2. **Success-after-retry:** TC awal gagal namun berhasil dalam retry yang sah.
3. **Timeout rate awal:** proporsi TC yang timeout pada eksekusi awal.
4. **Timeout rate akhir:** proporsi TC berstatus gagal timeout setelah retry selesai.

Rumus:

$$ Strict\ pass\ rate(\%) = \frac{Jumlah\ pass\ awal}{20} \times 100 $$

$$ Success\ after\ retry(\%) = \frac{Jumlah\ TC\ yang\ berhasil\ melalui\ retry}{20} \times 100 $$

$$ Timeout\ rate(\%) = \frac{Jumlah\ TC\ timeout}{20} \times 100 $$

2.8 Unit Analisis Statistik UAT dan Formula Agregasi

Agar tidak ambigu, analisis UAT dipisah menjadi dua unit:

1. **Per-item** (n = 10 responden per item): $ \bar{x}_j = \frac{1}{n}\sum_{i=1}^{n}x_{ij} $
2. **Per-responden** (k = 8 item per responden): $ y_i = \frac{1}{k}\sum_{j=1}^{k}x_{ij} $
3. **Rerata keseluruhan UAT** (berdasarkan nilai per-responden): $ \bar{y} = \frac{1}{n}\sum_{i=1}^{n}y_i $
4. **Standar deviasi (SD)** menggunakan **sample SD**: $ SD = \sqrt{\frac{\sum_{i=1}^{n}(y_i-\bar{y})^2}{n-1}} $
5. **Median dan IQR** dihitung dari distribusi y_i dengan metode Tukey (*median-of-halves*).
6. Seluruh angka desimal dilaporkan dengan pembulatan 2 digit menggunakan aturan **round half-up**.

2.9 Interpretasi Skala Likert

- 1,00–1,80: sangat tidak setuju
- 1,81–2,60: tidak setuju
- 2,61–3,40: netral
- 3,41–4,20: setuju
- 4,21–5,00: sangat setuju

2.10 *Threats to Validity* dan Mitigasi

Dimensi	Ancaman	Mitigasi
Internal	Variasi jaringan/latensi eksternal	Aturan retry terstandar, log timestamp-durasi-outcome
Construct	UAT ringkas (8 item) belum menutup seluruh UX	Klaim dibatasi pada penerimaan awal
External	Sampel kecil, satu konteks organisasi	Klaim sebagai *pilot terbatas*, bukan generalisasi

Reliability	Potensi inkonsistensi eksekusi skenario	Definisi TC kanonik + checklist eksekusi + verifikasi silang

2.11 Matriks Ketertelusuran (Kebutuhan → TC → Metrik → Bukti)

Kebutuhan (R)	TC terkait	Metrik utama	Evidence
R1. Otomasi berkas dasar	TC-01..TC-04	Pass rate per TC, durasi eksekusi	Lampiran A (tabel TC), log artefak file
R2. Eksekusi perintah sistem terkontrol	TC-05, TC-06, TC-15, TC-16	Pass/fail, kualitas pesan error	Lampiran A + catatan error handling
R3. Akuisisi informasi web	TC-07..TC-09	Relevansi sumber, keberhasilan fetch	Lampiran A + ringkasan sumber
R4. Orkestrasi multi-langkah	TC-12, TC-13, TC-20	Kelengkapan langkah dan sinkronisasi output	Lampiran A + artefak dokumen
R5. Keandalan layanan eksternal	TC-14	Timeout rate, retry outcome, total cycle time	Lampiran C (audit log TC-14)
R6. Penerimaan pengguna awal	U1..U8	Mean per-item, statistik agregat per-responden	Lampiran B (matriks skor UAT)

---

3. Hasil dan Pembahasan

3.1 Rekap Uji Fungsional *Black-Box*

Berdasarkan dataset final eksekusi TC-01..TC-20 (Lampiran A):

Metrik	Nilai
Total skenario	20
Pass awal (*strict*)	19
Fail awal	1
Strict pass rate	95%
Skenario berhasil setelah *retry*	1
Keberhasilan operasional akhir	100%
Timeout rate awal	5%
Timeout rate akhir	0%

Statistik durasi eksekusi awal (20 TC):

- Median: **19,00 detik**
- IQR: **14,20–27,70 detik**

- Min–maks: **7,90–120,00 detik**

Satu insiden *critical* terjadi pada TC-14 (timeout), namun pulih pada retry ke-1.

3.2 Hasil UAT: Statistik Deskriptif (Dataset Final)

3.2.1 Statistik per-item (n = 10)

Item	Mean	SD	Min	Maks
U1 Kemudahan penggunaan	4,30	0,48	4	5
U2 Kejelasan instruksi	4,20	0,42	4	5
U3 Relevansi hasil	4,10	0,32	4	5
U4 Kecepatan membantu tugas	4,00	0,47	3	5
U5 Pengurangan kerja manual	4,20	0,42	4	5
U6 Kenyamanan penggunaan ulang	4,10	0,32	4	5
U7 Kejelasan penanganan error	3,90	0,57	3	5
U8 Manfaat produktivitas	4,40	0,52	4	5

3.2.2 Statistik agregat per-responden (n = 10; rata-rata 8 item)

- Mean keseluruhan: **4,15**
- SD: **0,26**
- Min–maks: **3,75–4,63**
- Median: **4,13**
- IQR (Tukey): **4,00–4,38**

Interpretasi: penerimaan awal berada pada kategori **setuju**.

3.3 Forensik Insiden TC-14 (*Timeout*)

TC-14 menguji respons layanan eksternal dengan ambang 120 detik. Ringkasan jejak audit:

Timestamp (UTC)	Attempt	Timeout setting	Durasi aktual	Retry ke-	Outcome
2026-02-15T09:14:03Z	Initial	120 s	120 s	0	Timeout (Fail awal)
2026-02-15T09:16:18Z	Retry	120 s	47 s	1	Success

Parameter kontrol:

- Jeda antarcoba: 15 detik.
- Total cycle time TC-14: 120 + 15 + 47 = **182 detik**.

Makna operasional: kegagalan awal lebih terkait reliabilitas layanan eksternal dibanding kegagalan logika inti agen, tetapi tetap signifikan bagi SLA waktu pengguna.

3.4 Pembahasan

Hasil teknis (95% *strict pass rate*, 100% akhir) dan hasil pengguna (mean UAT 4,15) menunjukkan OpenClaw dapat dioperasionalkan untuk tugas administratif terstruktur pada fase awal adopsi. Namun, interpretasi harus defensif karena konteks studi terbatas. Temuan ini sejalan dengan literatur bahwa performa agen dipengaruhi interaksi kemampuan model, orkestrasi tool, dan reliabilitas lingkungan [3]–[5], [8]–[10].

Karena itu, studi ini diposisikan sebagai bukti **pilot terbatas**, bukan bukti superioritas umum.

3.5 Implikasi Praktis

1. Prioritaskan *timeout policy* bertingkat, retry adaptif, dan *fallback* layanan.
2. Wajibkan *logging* granular (timestamp, durasi, retry, outcome) untuk audit.
3. Standarkan SOP prompt/tugas untuk menekan variasi hasil.
4. Integrasikan aspek tata kelola dan *human-centered AI* sebelum skala adopsi diperluas [6], [7].

3.6 Keterbatasan

- Sampel kecil dan satu konteks organisasi.
- Tidak ada pembanding langsung dengan proses manual atau sistem lain.
- Ketergantungan pada layanan eksternal.
- Pengamatan jangka pendek.

---

4. Penutup

4.1 Kesimpulan

Implementasi OpenClaw menunjukkan kelayakan awal untuk otomasi tugas administratif terstruktur pada konteks terbatas. Secara teknis, diperoleh *strict pass rate* 95% (19/20) dengan satu insiden *timeout* awal (TC-14); melalui retry terkontrol, keberhasilan operasional akhir menjadi 100% (20/20). Dari sisi pengguna, UAT menunjukkan mean 4,15 (SD 0,26), yang mengindikasikan penerimaan awal pada kategori setuju.

Dengan mempertimbangkan keterbatasan metodologis, hasil ini merupakan **bukti pilot terbatas** dan memerlukan validasi lanjutan sebelum keputusan adopsi skala luas.

4.2 Saran

1. Terapkan retry adaptif dan *graceful timeout* untuk layanan eksternal.
2. Tingkatkan kualitas pesan error agar lebih operasional bagi pengguna non-teknis.
3. Lakukan studi lanjutan dengan sampel lebih besar, horizon lebih panjang, dan pembanding proses manual.
4. Tambahkan evaluasi tata kelola risiko AI, keamanan, dan privasi dalam desain berikutnya.

Daftar Pustaka

1. ISO/IEC 25010. (2011). *Systems and software engineering — Systems and software Quality Requirements and Evaluation (SQuaRE)*.
2. OpenAI. (2023). *GPT-4 Technical Report*. arXiv:2303.08774.
3. Xi, Z., Chen, W., Guo, X., et al. (2023). *The Rise and Potential of Large Language Model Based Agents: A Survey*. arXiv:2309.07864.

4. Yao, S., Zhao, J., Yu, D., et al. (2023). *ReAct: Synergizing Reasoning and Acting in Language Models*. ICLR.
5. Wu, Q., Bansal, G., Zhang, J., et al. (2023). *AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation*. arXiv:2308.08155.
6. NIST. (2023). *AI Risk Management Framework (AI RMF 1.0)*. National Institute of Standards and Technology.
7. Shneiderman, B. (2022). *Human-Centered AI*. Oxford University Press.
8. Wang, L., Ma, C., Feng, X., et al. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18, 186345.
9. Liu, X., Yu, T., Zhang, Z., et al. (2024). *AgentBench: Evaluating LLMs as Agents*. ICLR.
10. Jimenez, C. E., Yang, J., Wettig, A., et al. (2024). *SWE-bench: Can Language Models Resolve Real-World GitHub Issues?* ICLR.

Lampiran

- Instrumen uji dan dataset final: `/root/.openclaw/workspace/research/papers/openclaw-sinta4/instrumen-uji-openclaw.md`
- Checklist submit: `/root/.openclaw/workspace/research/papers/openclaw-sinta4/submit-pack-checklist.md`